GLOBAL SOLUTION 2026.1 · FIAP · ECONOMIA ESPACIAL

OrbiTerra

Inteligência espacial contra o estresse hídrico no café

Previsão de risco climático para lavouras de café combinando dados de satélite, sensores de campo (ESP32) e Inteligência Artificial.

Foco da POC	**Café arábica — corredor Mogiana Paulista / Sul de Minas**
Tema	**Economia espacial · Observação da Terra (downstream)**
Documento	**Conceito da solução — material de alinhamento do grupo**
Status	**Prova de Conceito (POC) — versão 1 para discussão**

Nota: "OrbiTerra" é um nome de trabalho — sinta-se à vontade para trocar com o grupo. Os campos de identificação (integrantes, RMs, links de repositório e vídeo) serão preenchidos na entrega final.

Do espaço ao pé da planta: satélite + sensor de campo + IA, transformando dado em decisão.

1. Resumo executivo

O **OrbiTerra** é uma prova de conceito que usa tecnologia espacial para proteger lavouras de café do estresse hídrico e climático. A solução cruza dados de **satélite** (índices de vegetação e temperatura de superfície) com leituras de um **sensor de campo baseado em ESP32** (umidade do solo, temperatura e umidade do ar) e aplica modelos de **Inteligência Artificial** (XGBoost e Random Forest) para antecipar a queda de produtividade antes que ela se torne irreversível.

Em uma frase: o satélite oferece a **visão macro** da lavoura; o ESP32 oferece a **visão micro**, no pé da planta; e a IA funde as duas para gerar um **alerta de risco** e uma recomendação de manejo, exibidos em um painel de decisão. O foco inicial é o corredor cafeeiro da **Mogiana Paulista e do Sul de Minas** — uma das regiões agrícolas mais sensíveis ao clima e estratégicas do país.

2. O desafio e a pergunta da GS

A Global Solution 2026.1 tem como tema a **economia espacial** e pede uma prova de conceito que responda à pergunta central:

> *"Como a tecnologia espacial pode ser utilizada para melhorar a vida das pessoas, tornar processos mais eficientes e criar novas oportunidades na Terra ou fora dela?"*

Nossa resposta: transformar dados de observação da Terra — hoje o maior mercado *downstream* da economia espacial — em decisões concretas para quem produz alimento. Satélites monitoram o clima, auxiliam o agronegócio e ajudam a evitar perdas; o OrbiTerra pega exatamente essa capacidade e a coloca a serviço de um problema real e mensurável: a perda de produtividade do café por falta d'água.

3. A ideia em detalhe

A maioria das ferramentas de monitoramento agrícola enxerga a lavoura de um único ângulo. O satélite vê de cima e a estação meteorológica vê o entorno — mas nenhum dos dois mede o que acontece **no solo, na zona da raiz**, que é onde a seca começa. O OrbiTerra resolve isso unindo três peças:

Os dois olhos e o cérebro

- **Olho macro (espaço):** imagens de satélite fornecem o índice de vegetação (NDVI/EVI), que mede o vigor da planta, e a temperatura de superfície — em série temporal e cobrindo grandes áreas.
- **Olho micro (campo):** um sensor ESP32 instalado na lavoura mede umidade do solo, temperatura e umidade do ar a cada poucos minutos, capturando o que o satélite não vê.
- **Cérebro (IA):** modelos de XGBoost e Random Forest aprendem a relação entre essas variáveis e o risco de estresse hídrico, prevendo problemas com antecedência.

O fluxo é simples de explicar: coletamos os dados das duas fontes, alinhamos tudo no tempo e no espaço com Python/Pandas, treinamos o modelo e exibimos o resultado num painel que mostra **onde** está o risco e **quando** agir. É uma POC — não precisa estar 100% operacional —, mas cada peça é construída sobre métodos já validados por instituições de pesquisa.

4. Por que café — e por que a Mogiana / Sul de Minas

A escolha não é arbitrária: ela vem de uma análise de onde a previsão de risco hídrico **mais agrega valor**. A soja mostra o tamanho do problema no Brasil — a seca causou cerca de US$ 80 bilhões em perdas na cultura em uma década, e o Rio Grande do Sul chega a perder uma safra a cada quatro. Mas a soja é a escolha óbvia (muitos grupos a usarão), o que aumenta o risco de soluções semelhantes. O café se destaca como alvo ideal para a nossa POC pelos seguintes motivos:

Critério	Café arábica (escolhido)	Soja (contexto macro)
Sensibilidade ao clima	Altíssima: faixa de tolerância estreita; secas recentes tiraram até 100% da produtividade em algumas áreas.	Alta, porém a planta tolera mais variação que o café.
Precedente científico	Direto: EMBRAPA mapeou café com HLS + Random Forest + XGBoost a +95% de precisão.	Vasto, mas com métodos parecidos aos do café.
Justificativa do ESP32	Forte: talhões pequenos e fragmentados são o ponto cego do satélite — o sensor de campo é decisivo.	Menor: grandes áreas homogêneas já são bem vistas do espaço.
Proximidade / demonstração	Local: Mogiana Paulista fica no interior de SP, perto da equipe.	Concentrada no Sul e Centro-Oeste.
Diferenciação (pódio)	Alta: escolha menos comum, menor risco de plágio.	Baixa: tema muito repetido entre grupos.

Decisão: produto = **café arábica**; região = **Mogiana Paulista / Sul de Minas**, com a soja entrando como pano de fundo que comprova a relevância nacional do problema.

5. Como a solução responde à pergunta da GS

A pergunta tem três partes — e o OrbiTerra responde diretamente a cada uma:

Melhorar a vida das pessoas

Antecipar a perda hídrica protege a renda do produtor (boa parte do café vem de pequenas e médias propriedades), reduz a quebra de safra que pressiona o preço ao consumidor e dá ao cafeicultor familiar uma ferramenta antes restrita a grandes empresas.

Tornar processos mais eficientes

A água é o recurso mais crítico do café. Saber **onde e quando** irrigar evita desperdício, direciona o manejo e substitui a decisão por intuição por decisão baseada em dado — exatamente o que a agricultura de precisão busca.

Criar novas oportunidades

A solução usa dados espaciais abertos para gerar um serviço de inteligência agrícola replicável e de baixo custo. Esse é o coração da economia espacial *downstream*: aplicações em observação da Terra podem movimentar centenas de bilhões de dólares até 2030, e a agricultura é um dos setores que mais capturam esse valor. O mesmo dado pode alimentar crédito rural e seguro agrícola paramétrico.

6. Arquitetura e a função de cada componente

A solução é organizada em cinco camadas. A tabela abaixo descreve o que cada peça faz e por que ela existe — ou seja, a função de tudo.

Componente	O que faz	Por que importa
Satélite óptico (Sentinel-2 / Landsat via HLS)	Mede NDVI/EVI — o vigor e a saúde da vegetação — ao longo do tempo.	Dá a visão macro, histórica e espacial da lavoura, de graça.
Produto térmico (MODIS LST)	Fornece a temperatura da superfície da lavoura.	Indica estresse térmico, que anda junto com o estresse hídrico.
Dados climáticos (CHIRPS, NASA POWER)	Precipitação e temperatura do ar da região, em série histórica.	São variáveis preditoras-chave e dão contexto meteorológico.
Estação de campo (ESP32 + sensor de solo + DHT22)	Mede umidade do solo na raiz e temperatura/umidade do ar a cada poucos minutos.	Enxerga o que o satélite não vê: subsolo, alta frequência e ponto exato.
Pipeline de dados (Python / Pandas)	Limpa, alinha e funde as fontes; calcula índices derivados (VCI, VHI) e variáveis.	Prepara um conjunto de dados consistente para o modelo aprender.
Modelo de IA (XGBoost / Random Forest)	Aprende a relação entre as variáveis e classifica o nível de risco / prevê a produtividade.	É o motor da previsão; comparamos modelos por R^2 e RMSE.
Painel de decisão (Streamlit / Plotly)	Mostra mapa, série de NDVI, alertas de risco e a recomendação de manejo.	Transforma o dado em decisão prática para o produtor.

7. O papel do ESP32 (e por que ele não é enfeite)

O ESP32 é a **estação de campo** que cobre os pontos cegos do satélite. Ele cumpre três funções dentro do projeto:

- **Vê o solo na zona da raiz.** O satélite só percebe a falta d'água depois que ela chega à folha; o solo seca antes, e é isso que o sensor de umidade mede — direto na fonte.
- **Cobre os buracos de tempo do satélite.** O Sentinel-2 passa a cada ~5 dias e a nuvem bloqueia a imagem óptica. Na época de chuva, podem-se passar semanas sem imagem limpa; o ESP32 mede a cada minutos.
- **Dá a medição pontual.** Mesmo a 10 metros, cada pixel é uma média de área; o sensor mede no pé da planta.

O ganho concreto: alerta antecipado

Imagine 10 dias de estiagem. O satélite passa no dia 1 (NDVI ainda normal, a planta não estressou), nubla do dia 2 ao 8, e a próxima imagem limpa só vem no dia 9 — já com o NDVI em queda, tarde demais. O ESP32, enquanto isso, viu a umidade do solo despencando desde o dia 2 e disparou o alerta no dia 3. São cerca de **seis dias de antecedência** para irrigar ou agir. Em resumo: o ESP32 funde a visão do espaço com a visão do campo — e é essa fusão que dá profundidade real à POC.

8. Fundamentação científica

Cada decisão do projeto se apoia em pesquisa de instituições reconhecidas:

- **Café por satélite + IA (EMBRAPA / Unicamp / INPE):** a combinação de imagens HLS com Random Forest e XGBoost mapeou cafezais e estágios fenológicos com mais de 95% de precisão, justamente em áreas fragmentadas de pequenas propriedades — o cenário do nosso alvo.
- **Previsão de safra operacional (EMBRAPA):** modelagem via satélite com índices de vegetação, precipitação e temperatura já atinge cerca de 80% de precisão na produtividade da cana, mostrando que o método funciona na prática.
- **Seca agrícola com Machine Learning:** em estudos de previsão de seca por sensoriamento remoto, o XGBoost lidera o desempenho (R^2 próximo de 0,96), usando indicadores como NDVI, temperatura de superfície e precipitação — os mesmos que usaremos.
- **Dados de campo são recomendados pela literatura:** revisões sobre previsão de seca pedem combinar sensoriamento remoto com coleta em campo e variáveis como umidade do solo — exatamente o que o ESP32 traz.
- **Economia espacial:** a observação da Terra pode gerar centenas de bilhões de dólares em valor downstream até 2030, com a agricultura entre os setores que mais se beneficiam.
- **Viabilidade com dado aberto:** Sentinel-2 (resolução de até 10 m, revisita de 5 dias), Landsat, MODIS e CHIRPS estão disponíveis gratuitamente via Google Earth Engine, com API em Python.

9. Como o projeto integra as disciplinas (Fases 3–4)

Um dos critérios do pódio é integrar o máximo de disciplinas. O OrbiTerra cobre, de forma natural, várias competências do curso:

Área / competência	Como aparece no projeto
Lógica e Python	Estruturas condicionais, laços e manipulação de dados na coleta e no processamento das fontes.
Análise de dados	Limpeza, integração e engenharia de variáveis com Pandas; estatística descritiva das séries.
Visualização	Gráficos com Matplotlib/Seaborn/Plotly e o painel de decisão (mapa, séries, alertas).
Machine Learning	Treino e comparação de XGBoost e Random Forest; avaliação por R^2, RMSE e acurácia.
IoT / sistemas embarcados	ESP32 com sensores de solo e ar, enviando leituras por WiFi (HTTP/MQTT) ao pipeline.
Banco de dados / APIs	Armazenamento das leituras e consumo de APIs de dados espaciais e climáticos.

Ajuste os nomes para as disciplinas exatas que o grupo cursou — a estrutura acima cobre as competências que o edital valoriza.

10. Plano de MVP e próximos passos

- Definir o talhão/área de estudo na Mogiana ou Sul de Minas e o período histórico de análise.
- Extrair a série de NDVI/EVI e temperatura de superfície via Google Earth Engine (Python).
- Montar a estação ESP32 — física, se o grupo tiver a placa; ou simulada em Python, se preferir (a POC permite os dois).
- Construir o conjunto de dados integrado (satélite + clima + sensor) com Pandas.
- Treinar e comparar XGBoost e Random Forest; reportar métricas e a variável mais influente.
- Construir o painel de decisão com mapa, séries e alertas de risco.
- Clonar o template do repositório, organizar o código e escrever os arquivos README.
- Gravar o vídeo de até 5 minutos (com a frase “QUERO CONCORRER”, se forem ao pódio) e montar o PDF final com os integrantes.

11. Fontes e referências

• EMBRAPA — Sensoriamento remoto com IA mapeia pequenos cafezais com elevada precisão (HLS + Random Forest + XGBoost). embrapa.br/busca-de-noticias

• Agência Gov / EMBRAPA, Unicamp, INPE, UFU — IA torna mais preciso o mapeamento da intensificação agrícola no Cerrado. agenciagov.ebc.com.br

• EMBRAPA — Automação e agricultura de precisão: previsão de safra da cana via satélite. embrapa.br/tema-automacao-e-agricultura-de-precisao

• EMBRAPA Soja / Zarc (via Valor) — Seca levou a perdas de US$ 80 bilhões na soja em uma década. visaoagro.com.br

• ScienceDirect — Agricultural drought forecasting using remote sensing (XGBoost, NDVI/LST/CHIRPS). sciencedirect.com/science/article/pii/S0378377425006365

• Springer / Natural Hazards — Forecasting drought using machine learning: a systematic literature review. link.springer.com

• Deloitte / World Economic Forum — Earth observation: a trillion-dollar opportunity / EO value by sector to 2030. deloitte.com; weforum.org

• Google Earth Engine — Catálogo de dados (Landsat, MODIS, Sentinel, CHIRPS) e API em Python. earthengine.google.com

• Mongabay Brasil; Notícias Agrícolas; SciELO (zoneamento agroclimático do café) — sensibilidade climática e estresse hídrico do café no Brasil.